



Identificación de Factores Determinantes en el Éxito de Campañas de Marketing Bancario

Integrante

Alejandro Orrego Roldan

Fundamentos de ciencia de datos

Maria Bernarda Salazar Sanchez

Facultad de Ingeniería

Universidad de Antioquia

Medellín, 2025

Identificación de Factores Determinantes en el Éxito de Campañas de Marketing Bancario

RESUMEN El presente estudio analiza un conjunto de datos de marketing directo de una institución bancaria portuguesa, con el objetivo de identificar los patrones que influyen en la suscripción de depósitos a plazo fijo. Utilizando una muestra de 45,211 registros, se aplicó una metodología rigurosa de ciencia de datos que abarcó desde la limpieza y tratamiento de valores atípicos hasta un Análisis Exploratorio de Datos (EDA) exhaustivo y preprocesamiento avanzado. Los resultados indican que variables como la duración de la llamada y el resultado de campañas previas son los predictores más fuertes del éxito, mientras que factores demográficos como la edad muestran una influencia menor. Asimismo, se generó un conjunto de datos transformado mediante técnicas de codificación y escalamiento, apto para el entrenamiento futuro de modelos de aprendizaje automático. Este trabajo proporciona una base cuantitativa para optimizar la eficiencia de las estrategias de contacto telefónico.

PALABRAS CLAVE: Marketing Bancario, Análisis Exploratorio de Datos (EDA), Preprocesamiento, Visualización de Datos, Segmentación de Clientes.

1. INTRODUCCIÓN

En el entorno financiero actual, la captación de recursos a través de depósitos a plazo fijo representa una fuente vital de liquidez para los bancos. Sin embargo, las campañas de marketing directo, específicamente el telemarketing, enfrentan desafíos crecientes debido a la saturación del mercado y la resistencia de los clientes a las llamadas intrusivas. La eficiencia de estas campañas no solo impacta los costos operativos, sino también la reputación de la entidad y la satisfacción del cliente.

Este artículo presenta un análisis integral del conjunto de datos "Bank Marketing", con el propósito de transformar datos históricos crudos en conocimiento estratégico accionable. El problema central abordado es la necesidad de distinguir, dentro de una vasta base de clientes, cuáles presentan una mayor probabilidad de conversión positiva.

Para ello, se desarrolló un flujo de trabajo de ciencia de datos estructurado en dos fases principales, documentadas en el repositorio del proyecto. En la primera fase, se realizó un diagnóstico de la calidad de los datos y un análisis exploratorio para entender la distribución y relación entre variables. En la segunda fase, se aplicaron técnicas de ingeniería de características, incluyendo la imputación de valores faltantes implícitos y la transformación numérica de variables categóricas. El resultado final no es solo un conjunto de hallazgos estadísticos sobre el perfil del cliente ideal, sino también un dataset depurado y estandarizado, listo para la implementación de modelos predictivos.

2. METODOLOGÍA

Para garantizar la reproducibilidad y el rigor científico del estudio, se adoptó la metodología del Ciclo de Vida de la Ciencia de Datos (Data Science Lifecycle). El flujo de trabajo se implementó utilizando el lenguaje de programación Python en un entorno de notebooks interactivos (Jupyter), haciendo uso de librerías especializadas como *Pandas* para manipulación de datos, *Seaborn/Matplotlib* para visualización y *Scikit-Learn* para el

preprocesamiento. Se utilizó el dataset "Bank Marketing" (Moro et al., 2014), proveniente de una institución bancaria portuguesa. El conjunto de datos original consta de 45,211 registros y 17 atributos, que incluyen variables demográficas (edad, trabajo, educación), financieras (saldo, historial de crédito) y relacionadas con la interacción de la campaña actual y previas. La variable objetivo es `deposit`, una variable binaria que indica si el cliente suscribió ('yes') o no ('no') el producto financiero.

En la etapa inicial, se realizó una inspección de calidad que reveló la ausencia de valores nulos explícitos y registros duplicados. Sin embargo, se detectó la presencia de valores "unknown" en las variables categóricas `job` (0.6%) y `education` (4.1%). Dado que estos porcentajes eran bajos, se procedió a una imputación basada en la moda (valor más frecuente) para mantener la integridad de la muestra sin introducir sesgos significativos. Como resultado de este proceso de limpieza, se generó el archivo denominado `bank_depurado.csv`, el cual sirvió como base para las fases subsiguientes de análisis y modelado.

Análisis Exploratorio (EDA)

Se implementó una estrategia de análisis estadístico descriptivo estructurada en tres niveles para validar la calidad de la información y comprender la estructura de las variables. En primer lugar, se ejecutó un análisis univariado, diferenciando las técnicas según el tipo de dato: para las variables categóricas se calcularon frecuencias relativas y absolutas visualizadas mediante gráficos de barras, con el fin de evaluar el desbalance de clases; para las variables numéricas, se examinaron las medidas de tendencia central y dispersión a través de histogramas y curvas de densidad, verificando la normalidad y la escala de las distribuciones.

En una segunda instancia, se abordó la detección de valores atípicos (outliers) aplicando una estrategia estadística combinada para asegurar la robustez del análisis. Se utilizaron dos métodos complementarios: el Rango Intercuartílico (IQR), visualizado mediante diagramas de caja (boxplots), y el cálculo del Z-Score (puntuación estándar), lo que permitió identificar observaciones extremas tanto por su posición en los cuartiles como por su desviación respecto a la media. El tratamiento de estos valores no fue automático; se sometieron a una revisión cualitativa basada en el conocimiento del dominio para decidir sobre los que requerirían eliminación y los que debían conservarse.

Finalmente, se realizó un análisis bivariado y multivariado para explorar la relación entre los atributos predictivos y la variable objetivo (`deposit`). Se utilizaron gráficos de cajas comparativos para contrastar las distribuciones de variables continuas según la respuesta del cliente. Asimismo, se calculó la matriz de correlación de Pearson, visualizada mediante mapas de calor (Heatmaps), para cuantificar la dependencia lineal entre variables numéricas y detectar posibles problemas de multicolinealidad antes del modelado. Complementariamente, se emplearon gráficos de dispersión por pares (Pairplots) para inspeccionar la separabilidad de las clases en un espacio multidimensional.

Preprocesamiento e Ingeniería de Características

Con el propósito de habilitar el uso de algoritmos de aprendizaje automático, que requieren entradas estrictamente numéricas y homogeneizadas, se diseñó un flujo de trabajo de transformación de datos que culminó en la generación del conjunto de datos `bank_preprocesado.csv`.

En primera instancia, se abordó la codificación de variables categóricas. Para la variable objetivo (`deposit`), se aplicó una transformación binaria simple (*Label Encoding*), asignando el valor 1 a la clase positiva ('yes') y 0 a la negativa ('no'). Por otro lado, para las variables predictoras nominales (como `job`, `marital` o `education`), se implementó la técnica de *One-Hot Encoding*. Se optó por este método en lugar de una codificación ordinal para evitar que los algoritmos interpretaran erróneamente un orden jerárquico inexistente entre las categorías (por ejemplo, asumir que "casado" es matemáticamente mayor que "soltero"). Además, se eliminó sistemáticamente la primera columna de cada categoría codificada (*drop_first*) para mitigar el riesgo de multicolinealidad perfecta, reduciendo la redundancia en la matriz de características.

Simultáneamente, se realizó el escalamiento de variables numéricas mediante la técnica de *MinMax Scaling*. Dado que el conjunto de datos original presentaba magnitudes dispares donde variables como `balance` alcanzaban valores de miles de euros mientras que `age` se mantenía en decenas, fue necesario normalizar todos los rangos al intervalo [0, 1]. Esta estandarización es crítica para asegurar que futuras implementaciones de modelos sensibles a la distancia (como K-Nearest Neighbors o Máquinas de Soporte Vectorial) o basados en gradientes (como Redes Neuronales) no se vean sesgados por la magnitud bruta de las variables, garantizando una convergencia más estable y equitativa.

RESULTADOS Y DISCUSIÓN

Panorama general y calidad de los datos

Tras el proceso de limpieza y depuración detallado en la metodología, el conjunto de datos final apto para el análisis constó de 45,211 registros. El análisis de la variable objetivo (`deposit`) reveló un desbalance de clases significativo: el 88.3% de los clientes rechazó la oferta, mientras que solo el 11.7% (5,289 clientes) suscribió el depósito a plazo. Este desbalance estructural representa un hallazgo crítico, pues indica que cualquier modelo predictivo entrenado con estos datos tendrá un sesgo natural hacia la clase mayoritaria ("no") si no se aplican técnicas de balanceo. Asimismo, confirma que la tasa de conversión de estas campañas telefónicas es baja, lo que justifica la necesidad de perfilar mejor a los candidatos para optimizar recursos.

Caracterización del perfil del cliente

El análisis univariado permitió identificar el perfil demográfico predominante en la cartera de clientes contactada. Se observó que la mayor parte de la población se concentra en cargos de "management" (administración), "blue-collar" (operarios) y "technician" (técnicos).

Un hallazgo interesante al cruzar estas variables con la tasa de éxito (análisis bivariado) es que, aunque los clientes con trabajos tipo "blue-collar" son numerosos, tienen una de las tasas de conversión más bajas. Por el contrario, los estudiantes y los jubilados ("retired"), a

pesar de ser grupos menos numerosos, mostraron una predisposición proporcionalmente mayor a aceptar la oferta (Ver Figura 1).




Figura 1. Distribución de suscripciones exitosas según la ocupación del cliente.

Esto sugiere que la estrategia comercial podría ser más efectiva si se diseñan guiones específicos para jubilados y estudiantes, quienes probablemente buscan seguridad financiera y ahorro, en contraste con perfiles activos que podrían preferir liquidez.

Factores determinantes del éxito de la campaña

La evidencia empírica señala inequívocamente a la variable *duration* como el factor discriminante más potente. Como se ilustra en la Figura 2, la distribución de la duración de las llamadas para los clientes que suscribieron el depósito ('yes') presenta una mediana significativamente superior (aprox. el doble) en comparación con los que rechazaron la oferta ('no'). El diagrama de cajas muestra que, aunque existen valores atípicos en ambos grupos, el 50% central de los casos exitosos se sitúa en rangos de tiempo mucho más elevados. Esto sugiere que el interés del cliente se traduce directamente en una mayor disposición a escuchar los detalles del producto.




Figura 2. Distribución de la duración de la llamada para clientes que aceptaron vs. rechazaron.

Aunque la duración es un indicador *ex post* (solo se sabe al finalizar la llamada), este hallazgo implica que los agentes no deben apresurar el cierre de la venta si detectan interés, ya que el tiempo invertido correlaciona positivamente con la confianza del cliente.

Complementando la interacción actual, el análisis reveló que el comportamiento histórico es un predictor robusto. Los datos mostraron que los clientes con un resultado de "success" en campañas previas (poutcome) tienen la tasa de conversión más alta de todo el conjunto, validando la importancia de la fidelización sobre la captación en frío. Asimismo, se evidenció una interconexión lógica entre la recencia (pdays) y la frecuencia (previous) del contacto, sugiriendo que la insistencia moderada en clientes conocidos refuerza la probabilidad de éxito.

Validación Técnica y Preparación para el Modelado

Para garantizar la robustez de los algoritmos de aprendizaje automático posteriores, fue necesario validar la estructura matemática del conjunto de datos. La matriz de correlación final (Ver Figura 3) confirmó que, tras las transformaciones y la eliminación de variables redundantes descrita en la metodología, no persiste una multicolinealidad crítica que pueda inestabilizar futuros modelos de regresión logística o redes neuronales.




Figura 3. Matriz de correlación de las variables numéricas transformadas.

Finalmente, como resultado del preprocesamiento, se obtuvo una matriz de características transformada y libre de inconsistencias numéricas. La aplicación de *One-Hot Encoding* generó nuevas variables binarias para categorías como estado civil y educación, permitiendo desagregar efectos individuales sin imponer una jerarquía ordinal artificial.

El escalamiento MinMax aplicado a variables como *balance* y *age* garantizó que todas las características numéricas se encuentren en el rango [0, 1], eliminando el sesgo de magnitud que presentaba el saldo bancario original (con valores de hasta 100,000 unidades) frente a la edad (decenas).

4. CONCLUSIONES

El presente estudio completó exitosamente el ciclo de vida de los datos para la campaña de marketing bancario, desde la limpieza inicial hasta la transformación técnica. Las evidencias estadísticas permiten derivar las siguientes conclusiones estratégicas y técnicas:

1. Se determinó que la duración de la llamada (*duration*) es el indicador más fiable de éxito. Esto sugiere un cambio de paradigma operativo: las estrategias de call center deben evolucionar de un enfoque de volumen (muchas llamadas cortas) a uno de calidad (interacciones profundas), ya que captar la atención del cliente correlaciona directamente con la conversión.
2. El historial transaccional es decisivo. El éxito en campañas previas (*previous_campaign_success*) es una garantía casi total de nueva suscripción. Se recomienda priorizar recursos en la re-captación de clientes satisfechos antes de explorar masivamente nuevos prospectos.
3. Aunque la edad general no es un discriminante fuerte, los extremos de la vida laboral (estudiantes y jubilados) representan nichos de alta efectividad que actualmente están subexplotados en comparación con los perfiles laborales activos.
4. Desde la perspectiva técnica, se ha logrado estructurar un pipeline de preprocesamiento robusto. El dataset resultante (*bank_preprocesado.csv*) elimina problemas de escala y codificación, permitiendo la implementación futura de modelos predictivos avanzados (Machine Learning) sin riesgo de sesgos por magnitud numérica o mala interpretación de categorías.

5. REFERENCIAS

Código Espinoza - Automatiza tu Vida. (2025). *Análisis Exploratorio de Datos (EDA) con Python: Descubre Insights Ocultos en tus Datos* [Video]. YouTube.

McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*.

Moro, S., Cortez, P., & Rita, P. (2014). A Data-Driven Approach to Predict the Success of Bank Telemarketing. *Decision Support Systems*, 62, 22-31.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Raúl Valerio - Statistics. (2025). *One Hot Encoding hecho fácil: Aprende a codificar tus datos categóricos con Python y Scikit-learn* [Video]. YouTube.

Waskom, M. L. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.

ENLACE AL REPOSITORIO

El código fuente, los datasets y el historial de versiones de este proyecto se encuentran disponibles públicamente en:

<https://github.com/AlejandroOrregoRoldan/Analisis-de-Datos.git>